




Mini Project: Time and Frequency Domain Analysis of Human Motion Signal

BTE5034 Digital Signal Processing, Frühlingssemester 2026
Final report

Autor/en:	Elyes Ben Chamakh, Suriya Kandasamy
Gruppe:	05
Datum:	2026-05-13
Betreuer:	Ridolfi Andrea

Abstract

Im Rahmen dieses Laborversuchs wurden Beschleunigungsdaten verschiedener menschlicher Bewegungsarten mithilfe des Axiamo X22 Motion Sensors aufgenommen und analysiert. Ziel des Versuchs war es, normales Gehen, schnelles Gehen und Rennen mithilfe von Methoden der digitalen Signalverarbeitung zu untersuchen und miteinander zu vergleichen. Für jede Aktivität wurden ungefähr zehn Sekunden Messdaten aufgenommen und anschliessend in Python importiert. Die Analyse der Signale erfolgte sowohl im Zeitbereich als auch im Frequenzbereich. Im Zeitbereich wurden die Signalformen, die Amplituden sowie die periodischen Eigenschaften der Bewegungen untersucht. Für die Frequenzanalyse wurden die Fast Fourier Transform (FFT), das Periodogramm und das Welch-Periodogramm verwendet, um dominante Frequenzanteile und Unterschiede der Schrittfrequenz zu bestimmen. Die Resultate zeigen deutliche Unterschiede zwischen den drei Bewegungsarten. Während normales Gehen kleinere Beschleunigungsamplituden und niedrigere dominante Frequenzen aufweist, erzeugt Rennen deutlich höhere Signalintensitäten und höhere Frequenzanteile. Die durchgeführten Analysen zeigen, dass Methoden der digitalen Signalverarbeitung gut geeignet sind, menschliche Bewegungen anhand von Sensordaten zu analysieren und charakteristische Merkmale verschiedener Aktivitäten zu identifizieren.

Inhaltsverzeichnis

1	Einleitung	4
2	Methoden und Materialien	5
2.1	Verwendete Materialien	5
2.2	Versuchsdurchführung	5
2.3	Datenverarbeitung	6
3	Aufgabe 1: Signalanalyse im Zeit- und Frequenzbereich	7
3.1	Zeitbereichsanalyse	7
3.2	FFT-Analyse	8
3.3	Periodogramm	9
3.4	Welch-Periodogramm	10
4	Aufgabe 2: Messprotokoll und Datenbasis	11
4.1	Dauer der Messungen	11
4.2	Einbezug mehrerer Testpersonen	11
5	Aufgabe 3: Entwicklung des Klassifikationsalgorithmus	12
5.1	Vorverarbeitung	12
5.2	Bandpassfilterung	12
5.3	Kadenzschätzung	13
5.4	Aktivitätsklassenidentifikation	13
5.5	Blockverarbeitung und Hauptfunktion	14
6	Aufgabe 4: Evaluation und Performanzanalys	15
6.1	Evaluationskriterien	15
6.2	Testdatensatz	15
6.3	Ergebnisse	15
7	Diskussion	16
8	Fazits	16
9	Literaturverzeichnis	17
10	Abbildungsverzeichnis	17

Abkürzungsverzeichnis

BFH	Berner Fachhochschule
FFT	Fast Fourier-Transformation
SciPy	Scientific Python
NumPy	Numerical Python

1 Einleitung

Beschleunigungssensoren werden heute in zahlreichen technischen Anwendungen eingesetzt. Sie finden Verwendung in Smartphones, Wearables, medizinischen Systemen sowie in der Bewegungs- und Sportanalyse. Mithilfe solcher Sensoren können Bewegungen präzise erfasst und ausgewertet werden. Die Analyse von Bewegungsdaten ermöglicht unter anderem die Bestimmung von Schrittfrequenz, Bewegungsintensität und charakteristischen Bewegungsmustern. Im Rahmen dieses Laborversuchs wurde der Axiomo X22 Motion Sensor verwendet, um Beschleunigungsdaten verschiedener menschlicher Aktivitäten aufzunehmen und zu analysieren. Gemäss der Versuchsanleitung arbeitet der Sensor mit einer Samplingfrequenz von 200 Hz [1].

Ziel des Versuchs war es, Unterschiede zwischen normalem Gehen, schnellem Gehen und Rennen mithilfe von Methoden der digitalen Signalverarbeitung sichtbar zu machen. Für jede Aktivität wurden ungefähr zehn Sekunden Messdaten aufgenommen. Die aufgezeichneten Signale wurden anschliessend in Python importiert und sowohl im Zeitbereich als auch im Frequenzbereich untersucht. Zur Frequenzanalyse wurden die Fast Fourier Transform (FFT), das Periodogramm und das Welch-Periodogramm verwendet.

Die Analyse im Zeitbereich ermöglicht die Untersuchung der Signalformen sowie der zeitlichen Veränderungen der Beschleunigung. Die Frequenzanalyse dient dazu, dominante Frequenzanteile und Unterschiede in der Schrittfrequenz der jeweiligen Bewegungsarten zu identifizieren. Die Darstellung und Analyse diskreter Signale im Zeit- und Frequenzbereich ist ein grundlegender Bestandteil der digitalen Signalverarbeitung [2] [3].

Es wird erwartet, dass sich die verschiedenen Aktivitäten deutlich in ihren Signalverläufen und Frequenzanteilen unterscheiden. Insbesondere sollte das Rennen höhere Beschleunigungsamplituden sowie höhere dominante Frequenzen aufweisen als normales Gehen. Der Versuch vermittelt grundlegende Kenntnisse im Bereich der Sensordatenerfassung, der Signalverarbeitung in Python sowie der Analyse diskreter Signale im Zeit- und Frequenzbereich.

Der vorliegende umfassende Bericht dokumentiert den gesamten Verlauf des Mini-Projects über alle vier Aufgaben hinweg. Aufgabe 1 behandelt die Vertrautmachung mit dem Sensor und der Datenanalyse im Zeit- und Frequenzbereich. Aufgabe 2 definiert das Messprotokoll, das zur Entwicklung des Algorithmus notwendig war. Aufgabe 3 beschreibt die Entwicklung des Klassifikationsalgorithmus, der ausschliesslich mit Methoden der digitalen Signalverarbeitung die Cadence schätzt und die Aktivität klassifiziert. Aufgabe 4 bewertet die Performance des Algorithmus anhand definierter Evaluationskriterien.

2 Methoden und Materialien

2.1 Verwendete Materialien

Für die Durchführung des Versuchs wurde der Axiomo X22 Motion Sensor verwendet. Der Sensor dient zur Aufnahme von Beschleunigungs- und Bewegungsdaten und arbeitet mit einer Samplingfrequenz von 200 Hz [1]. Zur Verarbeitung und Analyse der Messdaten wurde ein Computer mit installierter Python-Umgebung verwendet. Die Auswertung erfolgte in Visual Studio Code. Für die Datenanalyse und grafische Darstellung kamen die Python-Bibliotheken NumPy, Pandas, Matplotlib und SciPy zum Einsatz.

Die Einrichtung der Entwicklungsumgebung sowie die Konfiguration des Sensors erfolgten gemäss der bereitgestellten Quick-Start-Anleitung des Moduls BTE5034 [1].



Abbildung 1: Axiomo X22 Sensor [4]

2.2 Versuchsdurchführung

Ziel des Versuchs war die Aufnahme und Analyse von Beschleunigungsdaten verschiedener menschlicher Bewegungsarten. Dazu wurden drei unterschiedliche Aktivitäten untersucht:

1. Normales Gehen
2. Schnelles Gehen
3. Rennen

Vor Beginn der Messungen wurde der Axiomo X22 Sensor eingeschaltet und am Fuss befestigt. Nach dem Trennen vom Computer begann der Sensor automatisch mit der Aufzeichnung der Bewegungsdaten. Für jede Aktivität wurden ungefähr zehn Sekunden Messdaten aufgenommen. Während der Messungen wurde darauf geachtet, die Bewegungen möglichst konstant und gleichmässig auszuführen, um vergleichbare Datensätze zu erhalten. Nach Abschluss jeder Messung wurde der Sensor erneut über ein USB-C-Kabel mit dem Computer verbunden. Dadurch wurde die Aufzeichnung automatisch beendet und die gespeicherten Daten konnten heruntergeladen werden.

Die heruntergeladenen Rohdaten wurden anschliessend mithilfe der bereitgestellten Python-Skripte [5] verarbeitet und in ein lesbares Datenformat umgewandelt.

Für die Datenerfassung wurden drei Testpersonen rekrutiert, die sich in Körpergrösse, Gewicht und Fitnessniveau unterscheiden:

- Person A: 21 Jahre, 170 cm, 110 kg
- Person B: 21 Jahre, 175 cm, 70 kg
- Person C: 27 Jahre, 180 cm, 85 kg

Jede Person führte pro Aktivität mindestens zwei Durchläufe durch. Insgesamt wurden pro Aktivität ca. 10 Messungen aufgezeichnet. Der Axiomo X22 Sensor liefert nach jeder Messung fünf Ausgabedateien. Erfahrungsgemäss sind davon zwei Dateien brauchbar und enthalten die vollen 60 Sekunden Aufnahme; die übrigen drei sind kürzer oder weisen Artefakte auf (z. B. unvollständige Aufzeichnung, Synchronisationsfehler). Daher wurden für die weitere Analyse nur die validen 60-Sekunden-Messungen verwendet.

2.3 Datenverarbeitung

Nach dem Import der Messdaten in Python wurden die Signale im Zeitbereich sowie im Frequenzbereich analysiert.

Zunächst wurden die Beschleunigungssignale über der Zeit dargestellt. Dadurch konnten die Signalformen, die Beschleunigungsamplituden sowie die zeitlichen Abstände der einzelnen Schritte untersucht werden. Für die grafische Darstellung wurden jeweils vier repräsentative Sekunden jeder Messung ausgewählt.

Anschliessend erfolgte die Analyse im Frequenzbereich. Ziel dieser Untersuchung war die Bestimmung der dominanten Frequenzanteile und der Schrittfrequenzen der jeweiligen Bewegungsarten.

Für die Frequenzanalyse wurden folgende Methoden verwendet:

1. Fast Fourier Transform (FFT)
2. Periodogramm
3. Welch-Periodogramm

Die FFT ermöglicht die Zerlegung eines Signals in seine einzelnen Frequenzanteile. Das Periodogramm dient zur Darstellung der Leistungsverteilung eines Signals über der Frequenz. Das Welch-Periodogramm verbessert die spektrale Analyse durch die Mittelung mehrerer Signalabschnitte und liefert dadurch ein stabileres Frequenzspektrum [2] [3].

Die verschiedenen Methoden wurden verwendet, um Unterschiede zwischen normalem Gehen, schnellem Gehen und Rennen sowohl im Zeitbereich als auch im Frequenzbereich sichtbar zu machen.

Für die Aufgaben 2 bis 4 wurden die Daten für jede Aktivität jeweils in Blöcken von 5 Sekunden aufgeteilt und pro Block die Cadence sowie die Aktivitätsklasse bestimmt. Die Analyse im Frequenzbereich erfolgte mittels Welch-Periodogramm mit 2-Sekunden-Segmenten, 50% Überlappung und Hamming-Fenster, da diese Methode im Vergleich zum Standard-Periodogramm eine deutlich niedrigere Varianz aufweist

3 Aufgabe 1: Signalanalyse im Zeit- und Frequenzbereich

In diesem Abschnitt werden die Ergebnisse der aufgenommenen Bewegungsdaten dargestellt. Die Analyse erfolgte sowohl im Zeitbereich als auch im Frequenzbereich. Untersucht wurden die Bewegungsarten normales Gehen, schnelles Gehen und Rennen.

Die Resultate zeigen deutliche Unterschiede zwischen den drei Aktivitäten. Insbesondere konnten Unterschiede in den Signalamplituden, den periodischen Bewegungsmustern sowie den dominanten Frequenzanteilen festgestellt werden.

3.1 Zeitbereichsanalyse




Abbildung 2: Darstellung der Messdaten in der Time-domain

Abbildung 2 zeigt 4-Sekunden-Ausschnitte der Rohdaten für alle drei Aktivitäten (Beschleunigung in g, Winkelgeschwindigkeit in deg/s, jeweils drei Achsen).

- **Normales Gehen:** Über das gesamte 4-Sekunden-Fenster sind regelmässige, periodische Peaks in allen drei Achsen des Accelerometers und Gyroskops erkennbar. Dies entspricht dem erwarteten Verhalten einer echten Gehbewegung. Periodische Impulse, die den einzelnen Schritten zugeordnet werden können.
- **Schnelles Gehen:** Über das gesamte Fenster sind regelmässige Ausschläge sichtbar (Beschleunigung bis ± 5 g, Gyroskop bis ± 500 deg/s). Jeder einzelne Schritt ist klar abgrenzbar.
- **Rennen:** Auch hier ist die aktive Phase auf die zweite Fensterhälfte beschränkt. Die Gyroskop-Ausschläge sind kürzer und impulsartiger als beim schnellen Gehen, was auf einen Bewegungsablauf mit grösseren Stössen hindeutet.

Die Zeitbereichsanalyse zeigt, dass die Messungen für normales Gehen und schnelles Gehen eine stabile Periodizität aufweisen. Die Rennen-Messung aus Aufgabe 1 weist aufgrund einer zu kurzen aktiven Phase keine ausreichende Periodizität auf. Dies bestätigte jedoch den korrekten Betrieb der Analyse-Pipeline und zeigte gleichzeitig, welche Qualitätsanforderungen an die Daten zu stellen sind. Diese Erkenntnisse flossen direkt in die Definition des Messprotokolls in Aufgabe 2 (siehe Abschnitt 4) ein. Für die Entwicklung und den Test des Algorithmus in den Aufgaben 3 und 4 wurden daher alle Messungen neu erhoben und gemäss dem in Abschnitt 4 definierten Protokoll durchgeführt.

3.2 FFT-Analyse




Abbildung 3: FFT-Analyse der Messdaten

Die FFT-Amplitudenspektren (Abbildung 3) bestätigen den Befund aus der Zeitbereichsanalyse: Nur das schnelle Gehen erzeugt ein klares Linienspektrum mit erkennbarer Grundfrequenz und Harmonischen.

- **Normales Gehen:** Das Accelerometer-FFT-Spektrum zeigt einen deutlichen Peak bei sehr niedrigen Frequenzen (nahe 0 Hz), gefolgt von einem langsamen Abfall. Im Gyroskop-Spektrum dominiert die z-Achse mit sehr hohen Amplituden bei 0 Hz. Damit sind interpretierbare Harmonische sichtbar.
- **Schnelles Gehen (Beschleunigung):** Dominanter Peak bei ca. 2 Hz (Schrittfrequenz), gefolgt von abnehmenden Harmonischen bei 4, 6, 8 und 10 Hz. Im Gyroskop dominiert die x-Achse (Amplituden über 100'000 deg/s), was auf starke Rotationsbewegungen in der koronalen Ebene hinweist.
- **Rennen:** Die FFT zeigt nur einen dominanten Peak bei 0 Hz (Gravitation) und danach ein verschwindendes Spektrum ohne erkennbare Schrittfrequenz-Peaks. Die Problematik der zu kurzen aktiven Phase bleibt bestehen.

Die FFT macht deutlich, dass das schnelle Gehen die einzige Aktivität mit ausreichender Periodizität für eine zuverlässige Kadenzbestimmung ist. Für die anderen beiden liefert die FFT keine isolierten Peaks.

3.3 Periodogramm




Abbildung 4: Periodogramm

Das Periodogramm (Abbildung 4) schätzt die Leistungsverteilung $P_{xx}(f)$ und bestätigt die FFT-Ergebnisse, leidet jedoch, wie in den Vorlesungen beschrieben, unter hoher Varianz ("shaky values").

- **Normales Gehen:** Im Accelerometer ist der typische Abfall von tiefen Frequenzen erkennbar, das Spektrum ist jedoch stark verrauscht. Die Peaks sind zwar sichtbar, aber das "shaky"-Verhalten bleibt ein charakteristisches Merkmal des Periodogramms.
- Das schnelle Gehen hebt sich dennoch durch einen deutlich breiteren Dynamikbereich ab (Beschleunigung bis $100 \text{ g}^2/\text{Hz}$, Gyroskop bis $10^7 (\text{deg/s})^2/\text{Hz}$), mit wiederholt auftretenden schmalen Erhöhungen im Bereich 2–10 Hz.
- **Rennen:** Flaches Spektrum ohne ausgeprägte Peaks, konsistent mit der fehlenden periodischen Struktur im Zeitbereich.

Die hohe Varianz des Periodogramms erschwert die Identifikation der Schrittfrequenz. Eine Glättung durch Mittelung, wie beim Welch-Periodogramm, ist daher erforderlich.

3.4 Welch-Periodogramm




Abbildung 5: Welch-Periodogramm

Das Welch-Periodogramm (Abbildung 5) verwendet Segmentierung (1-Sekunden-Fenster, 50% Überlappung, Hamming-Fenster) und Mittelung, um die Varianz deutlich zu reduzieren. Die Kurven sind erwartungsgemäss wesentlich glatter und stabiler als im Standard-Periodogramm.

- **Normales Gehen:** Das Accelerometer-Welch-Periodogramm zeigt ein klares Spektrum mit abfallender Leistungsdichte über die Frequenzachse. Die drei Achsen (x, y, z) verlaufen ähnlich, was auf eine gleichmässige Bewegungsdynamik in alle Richtungen hindeutet. Das Gyroskop-Welch-Periodogramm zeigt dieselben Verläufe, jedoch mit deutlich höheren PSD-Werten.
- **Schnelles Gehen:** Die Spektren fallen kontinuierlich von hohen Werten bei tiefen Frequenzen ab. Die x-Achse des Gyroskops weist die höchste Leistungsdichte auf, konsistent mit der FFT. Auch wenn die Frequenzauflösung durch die kürzeren Segmente geringer ist, wird die Schrittcharakteristik klarer sichtbar.
- **Rennen:** Das Welch-Periodogramm liefert glattere Verläufe, jedoch weiterhin keine klar abgrenzbaren Schrittfrequenz-Peaks. Die zu kurze aktive Phase limitiert die Aussagekraft.

Zusammenfassend bestätigt die Welch-Methode die qualitativen Mängel der Messungen für normales Gehen und Rennen, zeigt aber gleichzeitig, dass die Analyse-Pipeline korrekt arbeitet. Für eine vollständige Demonstration der Leistungsfähigkeit wären neue Aufnahmen mit mindestens 10 Sekunden kontinuierlicher Aktivität pro Bewegungsart erforderlich.

4 Aufgabe 2: Messprotokoll und Datenbasis

In dieser Aufgabe wird ein Messprotokoll für die Erfassung von Bewegungsdaten definiert. Ziel ist ein Datensatz mit den drei Aktivitäten normales Gehen, schnelles Gehen und Rennen. Die Wahl der Messparameter wird theoretisch hergeleitet, unter anderem mit der Formel für die Frequenzauflösung des Periodogramms und der Varianzproblematik einfacher Periodogramme. Daraus folgen Empfehlungen für Messdauer, Segmentlänge, Anzahl der Segmente und Wiederholungen pro Aktivitätsklasse.

4.1 Dauer der Messungen

Aus der Theorie der digitalen Signalverarbeitung ergeben sich mehrere Argumente für eine Messdauer von mindestens 60 Sekunden pro Aktivität.

Die erforderliche Frequenzauflösung von $\Delta f = 0,2$ Hz bedingt mindestens 1000 Samples, was einer Mindestdauer von 5 Sekunden entspricht. Dieser Wert allein ist jedoch nicht ausreichend, da das einfache Periodogramm stark verrauscht ist und daher keine zuverlässige Spektralschätzung liefert.

Für eine glatte Leistungsdichteschätzung mittels des Welch-Periodogramms sind viele überlappende Segmente erforderlich. Bei einer Gesamtdauer von 60 Sekunden (12 000 Samples), einer Segmentlänge von 5 Sekunden (1000 Samples) und 50% Überlappung ergeben sich ca. 23 Segmente, wodurch die Varianz um den Faktor 23 reduziert wird.

Darüber hinaus konvergieren Mittelwert und Varianz als statistische Kennwerte erst ab einer Dauer von etwa 30–60 Sekunden zuverlässig. Auch die Autokorrelationsschätzung zur Bestimmung der Schrittperiode benötigt mindestens 30 Sekunden, um Randeffekte ausreichend klein zu halten.

Empfehlung: Jede Aktivität sollte über eine Dauer von 60 Sekunden aufgezeichnet werden.

4.2 Einbezug mehrerer Testpersonen

Die bisherigen Messungen stammen ausschliesslich von einer einzelnen Person. Um einen generalisierbaren Klassifikationsalgorithmus entwickeln zu können, sind Daten von mehreren Personen unerlässlich. Die Notwendigkeit ergibt sich aus mehreren Gründen. Erstens beeinflussen Körpergrösse, Beinlänge und der individuelle Laufstil die gemessenen Signaleigenschaften erheblich. Zweitens können sich die Schrittfrequenzbereiche überlappen, sodass schnelles Gehen einer Person im Bereich des normalen Gehens einer anderen Person liegen kann, was die Klassifikation erschwert. Drittens variiert die Position und der Sitz des Sensors am Schuh zwischen verschiedenen Personen und wirkt sich direkt auf das Signal aus. Viertens würde ein Algorithmus, der ausschliesslich auf den Daten einer Person trainiert wurde, nicht auf neue Nutzer verallgemeinern. Daher wird empfohlen, mindestens zwei bis fünf Testpersonen unterschiedlichen Alters, Geschlechts und Fitnessniveaus in die Messung einzubeziehen.

5 Aufgabe 3: Entwicklung des Klassifikationsalgorithmus

5.1 Vorverarbeitung

Der vom Sensor gelieferte Beschleunigungsvektor (x, y, z) enthält sowohl die durch Körperbewegungen verursachten dynamischen Anteile als auch die konstante Erdbeschleunigung (Gravitation). Um ausschliesslich die bewegungsinduzierte Beschleunigung zu erhalten, wird zunächst die Gesamtbeschleunigung (Magnitude) berechnet:

$$mag[n] = \sqrt{x[n]^2 + y[n]^2 + z[n]^2} \quad (1)$$

Die Gravitation wirkt als konstanter Offset auf dieses Signal. Somit wird der Mittelwert über das **gesamte** Signal bestimmt und subtrahiert:

$$mag_{AC}[n] = mag[n] - \frac{1}{N} * \sum_{n=0}^{N-1} mag[n] \quad (2)$$

Entscheidung für die globale Mittelwertsubtraktion: Da die Gravitation während der gesamten Messung konstant ist, muss der Abzug **einmalig** auf das komplette Signal angewendet werden. Ein blockweiser Abzug (wie in einer ersten Version fälschlicherweise implementiert) würde zu unterschiedlichen Offsets in den 5-Sekunden-Blöcken führen und die Kadenzschätzung verfälschen. Diese Korrektur ist konsistent mit der Definition des empirischen Mittelwerts aus der Vorlesung.

5.2 Bandpassfilterung

Menschliche Schrittfrequenzen liegen typischerweise zwischen 0.8 Hz (sehr langsames Gehen) und 3.5 Hz (schnelles Laufen). Höherfrequente Anteile (z. B. Vibrationen, Sensorrauschen) sowie niederfrequente Driftanteile stören die nachfolgende Kadenzschätzung. Daher wird ein Butterworth-Bandpass 4. Ordnung mit den Grenzfrequenzen 0.5 Hz und 5.0 Hz eingesetzt (Folie 3-50, Butterworth-Modell). Die Wahl der Butterworth-Charakteristik begründet sich durch den maximal flachen Durchlassbereich, der eine unverzerrte Übertragung der relevanten Schrittfrequenz gewährleistet.

Die Implementierung verwendet `scipy.signal.butter` zur Koeffizientenberechnung und `filtfilt` für eine nullphasige Filterung [3]. `filtfilt` vermeidet Phasenverzerrungen, indem der Filter einmal vorwärts und einmal rückwärts über das Signal angewendet wird. Dies ist besonders wichtig, da die Schritterkennung auf präzisen Zeitlagen basiert.

```
def bandpass_filter(signal, fs, lowcut=0.5, highcut=5.0, order=4):  
    nyquist = fs / 2.0  
    b, a = butter(order, [lowcut/nyquist, highcut/nyquist], btype='band')  
    return filtfilt(b, a, signal)
```

5.3 Kadenzschätzung

Die Kadenz (Schritte pro Minute) wird aus dem bandpassgefilterten Magnitudesignal ermittelt. Dazu wird für jeden 5-Sekunden-Block die biased Autokorrelation berechnet. Die Autokorrelation misst die Ähnlichkeit eines Signals mit seiner verzögerten Version. Bei einem periodischen Signal wie dem Schrittmuster entsteht ein ausgeprägter Peak bei der Verzögerung, die der Schrittperiode entspricht. Biased vs. Unbiased: Die biased Variante ($RB[k] = \frac{1}{N} * \sum_n nx[n+k]x[n]$) [2] liefert auch bei endlichen Signalen stabile Ergebnisse, insbesondere für grosse Verzögerungen. Daher wird diese verwendet. Schritte im Code:

1. Berechnung der vollen Kreuzkorrelation (mode='full')
2. Extraktion der positiven Lags (Autokorrelation ist symmetrisch)
3. Normierung durch die Blocklänge len(block) → biased Schätzung.
4. Suche des grössten Peaks im Bereich zwischen $fs/3.5$ und $fs/0.8$ Samples. Diese Grenzen entsprechen den minimalen bzw. maximalen Schrittfrequenzen.
5. Umrechnung der gefundenen Verzögerung peak_lag in Schritte pro Minute:

$$Cadence = 60 \cdot \frac{fs}{peak_{lag}} \quad (3)$$

Falls kein gültiger Peak gefunden wird, wird die Kadenz auf 0 gesetzt, was später zur Aktivität 0 (unbekannt) führt.

5.4 Aktivitätsklassenidentifikation

Tabelle 1: Aktivitätsklassen

Kadenz(steps/min)	Aktivitätsklasse	Code
≤ 0	unknown	0
< 70	Resting	1
70-110	Walking	2
110-140	Fast walking	3
> 140	Running	4

Die Schwellen wurden anhand der Referenzdaten empirisch bestimmt. Die Einführung einer eigenen Klasse für schnelles Gehen (Code 3, ursprünglich für Rennen reserviert, daher Verschiebung) erwies sich als notwendig, weil die Schrittfrequenzen und Amplituden von schnellem Gehen signifikant zwischen normalem Gehen und Rennen liegen. Ohne diese separate Klasse wurden schnelle Geh-Messungen fälschlich entweder als normales Gehen (zu tiefe Frequenz) oder als Rennen (zu hohe Amplitude) klassifiziert.

5.5 Blockverarbeitung und Hauptfunktion

Die Aufgabenstellung verlangt eine Funktion `activity_classifier(accelerationData, fs)`, die die Messdaten in Blöcke von 5 Sekunden unterteilt und für jeden Block Kadenz und Aktivität zurückgibt. Der implementierte Code erfüllt dies:

- Der Eingabevektor `accelerationData` kann entweder als (N,3) (Zeilen entsprechen Abtastwerten) oder als (3,N) vorliegen, beides wird unterstützt.
- Die Abtastrate `fs` wird in Hz übergeben.
- Es werden die ersten `num_blocks = len(x) / (5*fs)` vollständigen Blöcke verarbeitet
- Für jeden Block wird die bereinigte Magnitude (globaler Mittelwert bereits abgezogen) aus dem gefilterten Gesamtsignal entnommen. Es erfolgt **keine** erneute Mittelwertsabtraktion pro Block.

Wichtig: Die Gravitationskompensation wird **einmalig** auf das gesamte Signal angewendet, bevor die Blockteilung stattfindet. Dadurch wird sichergestellt, dass der Offset in allen Blöcken identisch ist. Ein zentraler Punkt, der in früheren Iterationen korrigiert werden musste.

6 Aufgabe 4: Evaluation und Performanzanalys

6.1 Evaluationskriterien

Um die Leistung des Algorithmus zu bewerten, wurden folgende Kriterien definiert. Die Genauigkeit (Accuracy) ist der Anteil der korrekt klassifizierten 5 Sekunden Blöcke im Verhältnis zu allen Blöcken. Zusätzlich wird der Recall pro Klasse berechnet (wie viele der tatsächlichen Blöcke einer Klasse wurden korrekt erkannt). Zur Visualisierung der Fehler wird eine Konfusionsmatrix (Confusion Matrix) erstellt, die zeigt, welche Klassen miteinander verwechselt wurden.

6.2 Testdatensatz

Als Testdatensatz wurden alle Pickle-Dateien im Ordner rawdata/X22/Excercise_2 verwendet. Dieser Datensatz wurde von uns selbst nach dem in Aufgabe 2 definierten Messprotokoll erhoben und umfasst je 25 Messungen pro Aktivitätsklasse (normales Gehen, schnelles Gehen, Rennen) sowie 4 weitere Einzelmessungen. Die Messungen wurden von mehreren Testpersonen durchgeführt, um eine gewisse Variabilität im Datensatz sicherzustellen. Die Ground Truth wurde aus dem Dateinamen abgeleitet: Enthält der Pfad „rennen“, wird Klasse 3 angenommen; enthält er „normal_gehen“ oder beginnt der Dateiname mit „..._gehen“, wird Klasse 2 angenommen. Insgesamt ergaben sich 455 vollständige 5-Sekunden-Blöcke über alle Dateien.

6.3 Ergebnisse

Der Algorithmus wurde auf diesem Testdatensatz ausgeführt. Die blockweise Genauigkeit (Accuracy) betrug 0,288, also nur 28,8 Prozent der Blöcke wurden korrekt klassifiziert. Die Konfusionsmatrix zeigt, dass die Ground Truth nur die Klassen 2 (Gehen) und 3 (Rennen) enthält. Kein Block hatte die Klassen 0 oder 1 in der Ground Truth. Für die Klasse Gehen (2) wurden 65 Blöcke fälschlich als Ruhen (1) klassifiziert, 59 Blöcke korrekt als Gehen (2) und 43 Blöcke fälschlich als Rennen (3). Für die Klasse Rennen (3) wurden 112 Blöcke fälschlich als Ruhen (1) klassifiziert, 104 Blöcke fälschlich als Gehen (2) und 72 Blöcke korrekt als Rennen (3). Der Recall für Gehen beträgt 0,353 (35,3 Prozent der echten Geh Blöcke wurden erkannt). Der Recall für Rennen beträgt 0,250 (25,0 Prozent der echten Renn Blöcke wurden erkannt). Die Klasse 0 (Unknown) und 1 (Ruhen) traten in der Ground Truth nicht auf, daher ist ihr Recall nicht definiert (0,0).

Nach der Einführung der fünften Aktivitätsklasse (schnelles Gehen) wurde der Algorithmus erneut auf dem Testdatensatz evaluiert. Die blockweise Genauigkeit verbesserte sich nur geringfügig auf 31,2 %. Jedoch zeigte die Konfusionsmatrix, dass Fehlklassifikationen zwischen normalem Gehen und schnellem Gehen um etwa 40 % zurückgingen. Dafür traten nun vereinzelt Verwechslungen zwischen schnellem Gehen und Rennen auf. Die geringe Gesamtgenauigkeit bleibt ein Indiz für die unzureichende Generalisierung auf fremde Daten.

7 Diskussion

Die implementierte Analyse-Pipeline arbeitet korrekt und liefert reproduzierbare Ergebnisse. Die visuelle Inspektion der Signale aus Aufgabe 1 zeigte, dass die erste Rennen-Messung qualitativ nicht ausreichend war. Dieser Befund war jedoch wertvoll, da er direkt in die Definition des Messprotokolls in Aufgabe 2 eingeflossen ist. Für die Aufgaben 3 und 4 wurde ein vollständig neuer Datensatz erhoben, der je 25 Messungen pro Aktivitätsklasse von mehreren Testpersonen umfasst. Damit basiert der Algorithmus auf einer deutlich breiteren Datenbasis als die initiale Exploration in Aufgabe 1.

Der in Aufgabe 3 entwickelte Algorithmus nutzt eine robuste Kombination aus Magnitudenberechnung, globaler Mittelwertsubtraktion, Bandpassfilter und Autokorrelation. Die Wahl der biased Autokorrelation und der nullphasigen Filterung ist fachlich korrekt. Die Tests in Aufgabe 4 zeigten jedoch eine geringe Genauigkeit von nur 28,8 Prozent auf einem unabhängigen Datensatz. Das liegt vor allem daran, dass der Algorithmus auf sehr wenigen und nicht repräsentativen Trainingsdaten basierte. Die Ground Truth Ableitung aus Dateinamen ist zwar einfach, aber möglicherweise nicht perfekt (z.B. können in einer Datei mit "rennen" auch ruhige Phasen vorkommen). Dennoch ist der grosse Unterschied zwischen den guten Ergebnissen auf den drei Entwicklungsdateien und den schlechten Ergebnissen auf dem gesamten Ordner ein klarer Hinweis auf mangelnde Generalisierung.

Um den Algorithmus praktisch brauchbar zu machen, wären folgende Schritte nötig: Aufnahme von mindestens 60 Sekunden pro Aktivität für jede der fünf Testpersonen, Verwendung eines echten Ground Truth Labels (z.B. durch gleichzeitige Videoaufzeichnung oder manuelles Markieren), Optimierung der Filterparameter und Schwellen auf einem separaten Validierungsdatsatz.

Ein zentrales Problem war die anfängliche Vernachlässigung der Klasse „schnelles Gehen“. In den ersten Messungen (Aufgabe 1) wurden nur normales Gehen und Rennen unterschieden. Die nachträgliche Erweiterung auf fünf Klassen konnte die Genauigkeit nicht wesentlich steigern, weil der Algorithmus nicht mit repräsentativen Trainingsdaten für schnelles Gehen konfiguriert wurde (die Schwellen wurden weiterhin aus den ursprünglichen drei Aktivitäten abgeleitet). Für eine echte Verbesserung wären separate Trainingsmessungen für schnelles Gehen mit definierten Kadenzbereichen (z. B. 111-130 Schritte/min) nötig gewesen.

8 Fazits

Im Rahmen dieses Projekts haben wir Beschleunigungsdaten verschiedener menschlicher Bewegungsarten mit dem Axiomo X22 Motion Sensor aufgenommen und analysiert. Die Daten wurden erfolgreich in Python importiert und sowohl im Zeit als auch im Frequenzbereich untersucht. Die Ergebnisse zeigen deutliche Unterschiede zwischen normalem Gehen, schnellem Gehen und Rennen. Rennen erzeugt höhere Beschleunigungsamplituden und höhere dominante Frequenzen.

Wir haben ein Messprotokoll erstellt, das eine Messdauer von 60 Sekunden pro Aktivität und den Einbezug mehrerer Testpersonen vorschreibt. Auf dieser Basis entwickelten wir einen Algorithmus, der die Kadenz schätzt und die Aktivität klassifiziert. Der Algorithmus arbeitet blockweise (5 Sekunden) und verwendet nur klassische DSP-Methoden.

Die Tests auf einem unabhängigen Datensatz ergaben jedoch nur eine blockweise Genauigkeit von 28,8 Prozent. Das zeigt, dass der Algorithmus auf die ursprünglichen Entwicklungsdaten überangepasst war. Für eine zuverlässige Klassifikation im echten Einsatz sind umfangreichere und vielfältigere Trainingsdaten notwendig. Dennoch vermittelte das Projekt grundlegende Kenntnisse in der Sensordatenerfassung, Signalverarbeitung mit Python und der Analyse diskreter Signale. Es zeigt, dass digitale Signalverarbeitung gut geeignet ist, menschliche Bewegungen zu charakterisieren, aber für eine robuste Aktivitätserkennung sorgfältig gesammelte Daten von vielen Personen benötigt werden.

9 Literaturverzeichnis

- [1] K. Reber, „BTE5034_labEx_Activity_Quick_Start“. 18. Februar 2026.
- [2] A. Ridolfi, „BTE5034_02_modelingAnalysis_HO“.
- [3] A. Ridolfi, „BTE5034_00_fundamentals_HO“.
- [4] A. Ridolfi, „BTE5034_miniProject_activityClassification“. 13. März 2025.
- [5] K. Reber, *x22_classroom_jupyter_V1*. Phyton.

10 Abbildungsverzeichnis

Abbildung 1: Axiamo X22 Sensor [4]	5
Abbildung 2: Darstellung der Messdaten in der Time-domain	7
Abbildung 3: FFT-Analyse der Messdaten	8
Abbildung 4: Periodogramm	9
Abbildung 5: Welch-Periodogramm	10